

Estadísticas descriptivas

Contents

- Análisis del Problema
- Estadísticas descriptivas univariadas
- Sobre la Ciencia de datos y la Visualización de datos
- Caso de estudio
- Conclusiones
- Documentación
- Referencias

Estadísticas descriptivas para datos espaciales

Para el contenido de esta sesión, se introduce a la exploración estadística de datos espaciales, para luego ejecutar un nuevo ejercicio práctico para la aplicación y puesta en práctica de los conceptos mencionados en un caso de estudio real dentro del IGAC.



Objetivos de la sesión

- Repasar características de interés en el análisis exploratorio para datos espaciales
- Sensibilizar sobre la conceptualización estadística para la exploración de datos espaciales
- Calcular estadísticas descriptivas a partir de capas de información vectorial
- Extraer conclusiones a partir de las salidas exploratorias de un caso de estudio



Recursos



[Recursos en línea de esta sesión](#)

Análisis del Problema



Nota

Al igual que en un estudio exploratorio clásico, cuando se dispone de información georreferenciada se pueden emplear histogramas, diagramas de tallos y hojas y de caja y bigotes (Chatfield. 1986) con el propósito de identificar localización, variabilidad, forma y observaciones extremas. Adicionalmente los gráficos de dispersión son muy útiles tanto para la detección de relaciones entre las variables como para la identificación de tendencias en el valor promedio de la variable en la región (relación entre la variable medida y las coordenadas geográficas) (Giraldo. 2002).

Estadísticas descriptivas univariadas

Conceptos: Dentro de los diferentes tipos de variables susceptibles de ser exploradas estadísticamente, estas se agrupan de la siguiente forma:

- **Variables Cualitativas:** Son características o cualidades que no se pueden expresar con números, sino con palabras o categorías. Ejemplos: lugar de nacimiento, cobertura de suelo, uso del suelo. Municipio al que pertenece un centro poblado.
 - *Tipo nominal:* categorías sin orden inherente. Ejemplo: departamento al que pertenece un municipio.
 - *Tipo ordinal:* categorías con un orden o jerarquía. Ejemplo: estratos socio-económicos.
- **Variables cuantitativas:** son características o cualidades que pueden expresarse o medirse con números. Ejemplos: elevación, altura, temperatura, salinidad, número de habitantes
 - *Tipo discreta:* Solo pueden tomar valores enteros. Ejemplo: número de habitantes.
 - *Tipo continua:* Pueden tomar cualquier valor dentro de un rango. Ejemplo: el tiempo.

Dentro de las diferentes estadísticas univariadas que podemos encontrar, estas se agrupan de la siguiente forma:

- **Localización:** son valores que describen el centro de una distribución de datos, dentro de las que están:
 - *Media:* Medida de tendencia central. Es el promedio aritmético de todos los valores en un conjunto de datos.
 - *Mediana:* Medida de tendencia central. Es el valor central de un conjunto de datos ordenados, que divide los datos en dos mitades iguales.
 - *Moda:* Medida de tendencia central. Es el valor que aparece con mayor frecuencia en un conjunto de datos.
 - *Cuartiles:* Dividen los datos en cuatro partes iguales.
 - *Percentiles:* Dividen los datos en 100 partes iguales. Especialmente útiles para la detección de datos atípicos
- **Variabilidad:** cuantifican la dispersión o extensión de un conjunto de datos, indicando cuán diferentes o dispersos están los valores individuales.
 - *Rango:* diferencia entre el valor máximo y el valor mínimo de un conjunto de datos.
 - *Varianza:* medida de la dispersión de los datos con respecto a su media, calculada como la media de los cuadrados de las diferencias entre cada valor y la media.
 - *Desviación estándar:* raíz cuadrada de la varianza, que proporciona una medida de la dispersión en las mismas unidades que los datos originales.
 - *Rango intercuartil:* diferencia entre el tercer cuartil (Q3) y el primer cuartil (Q1), que representa la dispersión de la mitad central de los datos.
 - *Coeficiente de variación:* medida de dispersión relativa que permite comparar la variabilidad de dos o más conjuntos de datos con diferentes medias.
- **Forma:** describen la forma de una distribución de datos, como la simetría, asimetría, concentración y apuntamiento, para clasificarla.
 - *Simetría:* indica si los datos se distribuyen de manera uniforme a ambos lados de la media. Se puede medir con el coeficiente de asimetría de Pearson o el coeficiente de asimetría de Fisher.
 - *Asimetría:* describe el grado de desequilibrio en la distribución. Una distribución asimétrica tiene una cola más larga en un lado que en el otro.
 - *Concentración:* Mide la dispersión de los datos. Una distribución con alta concentración tiene la mayor parte de los datos agrupados en un área pequeña.
 - *Curtosis:* indica si la distribución es más o menos 'picuda' o 'aplanada' en comparación con una distribución normal. Se puede medir con el coeficiente de

curtosis.

⚠ Importante recordar

- La aplicación de las diferentes estadísticas univariadas y la misma fórmula para sus cálculos depende del tipo de variable a explorar.

! Actividad

- **Interiorizar los conceptos que cubren las definiciones anteriores permite la investigación objetiva a partir de datos. Se insta a repasar sobre la funcionalidad estadística, las ventajas y desventajas de usar una u otra posibilidad de estadística, así como una u otra representación por tipo de variable para la medición de un fenómeno**




Fig.1. Boxplot mostrando el sesgo de algunos conjuntos de datos (Chae. 2019)

Sobre la Ciencia de datos y la Visualización de datos



Nota

El mercado del software de 'Inteligencia de Negocios' hace énfasis estético del uso de gráficos estadísticos y de interfaces enfocados en los valores de la oportunidad y la practicidad para usuarios no expertos en estadística ni en Sistemas de Información Geográfica.

Los docentes de este diplomado, en calidad de usuarios del software libre, hacen énfasis en los valores de la autonomía y la perspicacia, los cuales son habilitadores del provecho a las herramientas de software libre como Python.

Habiendo mencionado la anterior clasificación de variables:



Nota

El uso de un tipo de gráfico u otro dentro de una opción está delimitado por las opciones en consideración a los tipos de variables estudiadas, pero más aún:

- por las opciones que el software utilizado induzca a que sean utilizados,
- por las preferencias estéticas del usuario.

Se hace pertinente detenerse a observar los siguientes posibles elementos de diseño de un gráfico estadístico:



Elementos gráficos:

- puntos
- líneas
- barras



Representación de las multidimensionalidad:

- cardinalidad
- escala de color
- animación
- tamaño o volumen

Caso de estudio

Tamaño de unidades de análisis para modelo *Deep Learning*

Se requiere determinar el tamaño de una ventana de recorte de datos ráster multibanda para los datos del periodo 2018 del municipio de Chía con el fin de alimentar un modelo de regresión para estimar número de construcciones y número de habitantes a partir de imágenes de satélite. A continuación se observa el esquema del modelo Deep Learning que asocia cada recorte ráster a un valor de número de construcciones (o de habitantes). Se sabe que la resolución de las imágenes es de 10 metros.




Fig.2. Arquitectura de Red Neuronal Artificial para regresión espacial (Doupe et al. 2016).

! Actividad

- Por favor, desplegar el *notebook* compartido en Google Colab.

Consideraciones para el *notebook*

Para la impresión de valores con decimales, en el caso de la librería *pandas*, es posible acotar la cantidad de decimales a imprimir, de manera de que la lectura de las cifras sea agradable y de fácil comparación.

```
pd.set_option('display.float_format', lambda x: '%.1f' % x)
```

Resultados del *notebook*

! Actividad

- Generar conclusiones pertinentes al problema planteado en el caso de estudio a partir de las salidas del *notebook*.


! Actividad

- Reflexione sobre las posibilidades de tipos de gráficos estadísticos que usted hubiese podido utilizar e incluso preferir, en los lineamientos del problema del caso de estudio planteado.

	count	mean	std	min	25%	50%	75%	90%	max
Area_constr	43669.0	95.4	280.5	0.4	28.1	57.5	101.4	176.3	28226.3
Area_constr_dentro_perim_urb	25177.0	75.9	179.6	0.4	20.8	47.9	82.9	137.4	16312.7
Area_constr_fuera_perim_urb	18492.0	121.9	375.1	1.2	37.5	75.2	124.7	228.6	28226.3
Area_constr_cabec_mpal	34956.0	84.9	270.2	0.4	24.4	53.5	93.5	155.4	28226.3
Area_constr_centro_pob	3852.0	88.7	87.8	2.0	37.3	67.9	107.6	173.5	1124.1
Area_mzn	776.0	36290.8	133162.4	244.3	3744.1	10574.9	33116.8	69405.7	2229962.3
Area_constr_rurales	4861.0	175.8	410.3	1.2	43.5	85.3	180.0	353.8	11319.9
Area_mzn_dentro_perim_urb	434.0	17230.6	34697.4	244.3	1973.9	6747.0	16675.9	42956.0	313335.6
Area_mzn_fuera_perim_urb	342.0	60478.3	194223.2	401.4	7519.6	22735.4	52586.2	108853.4	2229962.3
Area_mzn_cabec_mpal	603.0	28820.9	66256.5	244.3	2604.2	9223.4	26194.2	67082.2	1120613.0
Area_mzn_centro_pob	82.0	52507.8	245537.0	401.4	5722.9	14384.3	34392.6	65668.0	2229962.3

Tabla 1. Estadísticas descriptivas univariadas para el área de las manzanas y construcciones de Chía.

Se resalta que el uso de métodos para cruces de tablas de *pandas* permite obtener una salida tabular comparable en sí misma entre las diferentes estadísticas, las diferentes categorías de suelo y las diferentes unidades de investigación. Para el caso de estudio, categorizando según el uso del suelo, según si es cabecera, centro poblado o área rural y según si se es una manzana o una construcción.






Fig.3. Matrix plot para las estadísticas descriptivas univariadas del área de las manzanas de Chía.




Fig.4. Matrix plot para las estadísticas descriptivas univariadas del área de las construcciones de Chía.

La escogencia del uso de un tipo de gráfica u otra, más de la dependencia y la adecuación del tipo de variables estudiadas, dependen de las hipótesis y los argumentos generados por el investigador. Cabe observar cómo estos datos pudieron ser revisados en histogramas para la representación y comparación de distribuciones, así como diagramas de dispersión y *boxplots*. En este caso, el investigador condensó la representación en solo dos *matrix plots* para la exposición de sus argumentos.

	count	mean	std	min	25%	50%	75%	90%	max
Ampl_oo_constr	43669.0	11.4	9.6	0.5	6.3	9.5	13.3	18.8	316.7
Ampl_oo_constr_dentro_perim_urb	25177.0	10.6	8.7	0.5	6.0	9.0	12.4	17.3	219.5
Ampl_oo_constr_fuera_perim_urb	18492.0	12.5	10.6	0.6	7.0	10.3	14.5	21.0	316.7
Ampl_oo_constr_cabec_mpal	34956.0	10.8	8.9	0.5	6.0	9.3	12.9	17.7	316.7
Ampl_oo_constr_centro_pob	3852.0	11.3	7.6	0.9	7.0	10.0	13.0	17.6	90.2
Ampl_oo_mzn	776.0	193.8	185.6	10.1	77.7	135.4	253.4	403.2	1555.4
Ampl_oo_constr_rurales	4861.0	15.4	14.0	1.0	7.4	11.2	18.6	29.9	192.8
Ampl_oo_mzn_dentro_perim_urb	434.0	144.7	138.5	10.4	64.9	99.0	168.1	302.0	1014.3
Ampl_oo_mzn_fuera_perim_urb	342.0	256.1	216.6	10.1	112.8	210.9	338.4	461.9	1555.4
Ampl_oo_mzn_cabec_mpal	603.0	178.3	169.6	10.4	70.0	124.6	229.7	382.4	1555.4
Ampl_oo_mzn_centro_pob	82.0	215.5	201.8	10.1	101.4	176.2	269.5	382.2	1392.8
Ampl_ns_constr	43669.0	7.8	6.0	0.2	4.4	6.6	9.5	13.5	198.9
Ampl_ns_constr_dentro_perim_urb	25177.0	6.6	4.9	0.4	3.5	6.0	8.0	11.0	137.7
Ampl_ns_constr_fuera_perim_urb	18492.0	9.3	6.9	0.2	5.5	8.0	11.3	16.0	198.9
Ampl_ns_constr_cabec_mpal	34956.0	7.3	5.5	0.2	4.0	6.2	9.0	12.5	198.9
Ampl_ns_constr_centro_pob	3852.0	8.4	4.7	0.5	5.7	7.4	10.3	14.0	66.0
Ampl_ns_mzn	776.0	140.1	166.4	7.2	49.7	95.2	174.1	274.6	2163.6

Ampli_oo_man	770.0	170.1	100.7	7.2	70.7	50.2	177.7	277.0	2700.0
Ampl_ns_constr_rurales	4861.0	10.9	8.7	0.5	6.0	8.5	13.3	20.0	122.0
Ampl_ns_mzn_dentro_perim_urb	434.0	99.4	91.7	7.5	35.2	75.1	124.5	209.6	579.7
Ampl_ns_mzn_fuera_perim_urb	342.0	191.8	217.9	7.2	84.5	137.4	235.9	367.2	2163.6
Ampl_ns_mzn_cabec_mpal	603.0	129.8	130.5	7.5	41.6	88.4	172.0	277.4	1207.3
Ampl_ns_mzn_centra_pob	82.0	160.4	246.7	7.2	73.8	120.5	167.0	258.2	2163.6

Tabla 2. Estadísticas descriptivas univariadas para las amplitudes de las manzanas y construcciones de Chía.

A diferencia de la **tabla 1**, la **tabla 2** puede abrumar a causa de su tamaño y mayor dificultad para interpretar y comparar. Es sugerible editarla, agrupando las diferentes categorías, para que la búsqueda entre categorías se facilite.




Fig.5. *Matrix plot* para las estadísticas descriptivas univariadas de las amplitudes por orientación de las manzanas de Chía.




Fig.6. *Matrix plot* para las estadísticas descriptivas univariadas del las amplitudes por orientación de las construcciones de Chía.

Cabe mencionar que se observa una diferencia entre las estadísticas de la orientación nort-sur y la orientación oriente-occidente. Este mismo gráfico está permitiendo a la vez comparar las diferentes distribuciones de datos e inferir su forma de manera indirecta. La escala de colores permite distinguir los cambios sutiles entre una distribución y otra.

! Actividad

- **Afirme sobre un posible tamaño de ventana, en donde sea factible contener espacialmente las unidades de investigación, descartando a la vez posible *outliers* y por supuesto la resolución de las capas de información ráster que compondrían las unidades de observación para el modelo de Red Neuronal Artificial**

Conclusiones

💡 Nota

Se ha buscado sensibilizar sobre la interiorización de los elementos que componen la exploración de datos, previa a cualquier inferencia y modelado a partir de los mismos. Aparte de lo que próximamente se menciona en el diplomado, se resalta que no es requerido procesar datos espaciales con un software licenciado de hojas de cálculo, y que a pesar de cualquier limitante en materia de soporte, en la práctica, el dueño del proceso desarrollado es **usted**.

Documentación

1. [Documentación de la librería *pandas*](#)
2. [Documentación de la librería *matplotlib*](#)

Referencias

- Chatfield, Chris. 1986. "Exploratory Data Analysis." European Journal of Operational Research 23 (1): 5–13. [https://doi.org/https://doi.org/10.1016/0377-2217\(86\)90209-2](https://doi.org/https://doi.org/10.1016/0377-2217(86)90209-2).

- Giraldo, Ramón. 2002. "Introducción a La Geoestadística: Teoría y Aplicación." Bogotá: Universidad Nacional de Colombia.
- Doupe, Patrick, Emilie Bruzelius, James Faghmous, and Samuel Ruchman. 2016. "Equitable Development Through Deep Learning: The Case of Sub-National Population Density Estimation." In, 1–10. <https://doi.org/10.1145/3001913.3001921>.
- Chae, Ever. (2019) Box-plots displaying the skewness of the data set. https://en.wikipedia.org/wiki/Box_plot#/media/File:Boxplots_with_skewness.png

[Guías de aprendizaje](#) © 2025 by [Aníbal Montero](#) is licensed under [CC BY-NC-ND 4.0](#)    

