

Reducción de Dimensionalidad

Contents

- Análisis del Problema
- Análisis de Componentes Principales (PCA)
- Random Forest (RF)
- Caso de estudio
- Conclusiones
- Documentación
- Referencias

Aplicación de Análisis de Componentes Principales y *Random Forest* en datos espaciales

Para el contenido de esta sesión, se muestran dos técnicas ampliamente utilizadas para la selección de características, mencionando las ventajas y desventajas que esto conlleva.



Objetivos de la sesión

- Introducir en la necesidad de realizar reducción de dimensionalidad y en las alternativas comunes para abordar el problema
- Entender el concepto que comprende la técnica de Análisis de Componentes principales (PCA) para la reducción de dimensionalidad
- Entender el concepto que comprende la técnica de *Random Forest* (RF) para la reducción de dimensionalidad
- Abordar un ejercicio práctico de preprocesamiento y análisis de salidas gráficas para reducción de dimensionalidad

Recursos

 [Recursos en línea de esta sesión](#)

Actividad

- **Dejar ejecutando el material de la sesión durante la clase, ya que puede tardar.**

Análisis del Problema

. * **¿Qué significa reducir la dimensionalidad?**: Reducción de la dimensionalidad es son un conjunto de técnicas de aprendizaje automático y análisis de datos que consisten en transformar los datos de alta dimensión en un espacio de menor dimensión, conservando tanta información importante como sea posible (Awan. 2025). Los datos de alta dimensión se refieren a conjuntos de datos con un número de características o variables que puede plantear retos para el modelado de estos mismos datos.

- **¿Para qué se realiza reducción de la dimensionalidad en un conjunto de datos?**: Los datos de alta dimensión, aunque ricos en información, a menudo contienen características redundantes o irrelevantes. Esto puede dar lugar a varios problemas (Awan. 2025):
 - *Maldición de la dimensionalidad*: A medida que aumenta el número de dimensiones, los puntos de datos se vuelven dispersos, lo que dificulta que los modelos de aprendizaje automático encuentren patrones.
 - *Sobreajuste*: Los conjuntos de datos de alta dimensión pueden hacer que los modelos se ajusten en exceso, ya que pueden aprender ruido en lugar de los patrones subyacentes.
 - *Complejidad computacional*: Más dimensiones significan mayores costes computacionales, que pueden ralentizar el entrenamiento y la inferencia.
 - *Retos de visualización*: Visualizar datos con más de tres dimensiones dificulta la comprensión de la estructura de los datos.

La reducción de la dimensionalidad aborda estos problemas simplificando los datos y conservando sus características más importantes. Esto no sólo mejora el rendimiento del

modelo, sino que también facilita la interpretación y visualización de los datos.

- **Tipos de reducción de dimensionalidad:** Las técnicas de reducción de la dimensionalidad pueden clasificarse a grandes rasgos en dos tipos: Selección y extracción de rasgo (Awan. 2025).
 - *Selección de características:* La selección de rasgos consiste en identificar y conservar sólo los rasgos más relevantes del conjunto de datos. Este proceso no transforma los datos, sino que selecciona un subconjunto de las características originales. Entre las técnicas habituales se incluyen:
 - Métodos de filtrado (Utiliza medidas estadísticas para clasificar y seleccionar características)
 - Métodos de envoltura (Utiliza modelos de aprendizaje automático para evaluar subconjuntos de características)
 - Métodos integrados (Realiza la selección de características durante el entrenamiento del modelo)
 - *Extracción de rasgos:* también conocida como proyección de rasgos, transforma los datos en un espacio de menor dimensión creando nuevos rasgos que son combinaciones de los originales. Este enfoque es especialmente útil cuando las características originales están muy correlacionadas o son redundantes. Entre las técnicas populares de extracción de rasgos se incluyen:
 - Principal Component Analysis (PCA)
 - Latent Dirichlet allocation (LDA)
 - t-SNE, UMAP y autocodificadores



Nota

Las opciones de técnicas de reducción de dimensionalidad varían de acuerdo a la estructura de datos y al fenómeno que se esté estudiando, por lo que las técnicas son numerosas.

! Actividad

- Realizar una charla con una IA de Procesamiento de Lenguaje Natural sobre más opciones de técnicas y aplicaciones de reducción de dimensionalidad, preguntando sobre dónde es más adecuada una u otra opción de técnica.

Análisis de Componentes Principales (PCA)

El Análisis de Componentes Principales, conocida en inglés como *Principal Component Analysis* (PCA), es una técnica fundamental para simplificar y explorar conjuntos de datos complejos. Su objetivo principal es transformar un conjunto de variables linealmente correlacionadas en un nuevo conjunto de variables linealmente no correlacionadas, llamadas componentes principales, que capturan la mayor parte de la variabilidad presente en los datos originales.

- **Variabilidad:** Referido a qué tanto difieren las observaciones de una variable entre sí. También referido a la dispersión, diversidad, incertidumbre o heterogeneidad de los valores dentro de un conjunto de datos. La cuantificación de la variabilidad se realiza mediante métricas como la varianza, la desviación estándar o el rango intercuartílico.
- **Correlación lineal:** es una medida estadística que cuantifica la relación de dependencia directa o inversa entre dos variables cuantitativas. Indica en qué medida los cambios en una variable tienden a asociarse con cambios proporcionales en la otra, siguiendo una tendencia lineal. Su valor oscila entre -1 (correlación negativa perfecta), 0 (ausencia de correlación lineal) y 1 (correlación positiva perfecta).




Fig.1. Correlaciones de Pearson tomadas en diferentes nubes de puntos bidimensionales (Boigelot et al, 2011)

El PCA es especialmente útil en contextos donde la dimensionalidad de los datos es alta, ya que permite reducir el número de variables manteniendo la mayor cantidad de información posible.

- **Información:** En el contexto de la Estadística, se refiere a los patrones, relaciones o estructuras significativas que pueden extraerse de los datos para reducir la incertidumbre en la toma de decisiones. Se cuantifica mediante medidas como la entropía, la ganancia de información o la varianza, que evalúan cómo los datos permiten distinguir entre diferentes hipótesis o predicciones.

Cada componente principal es una combinación lineal de las variables originales, ordenadas de manera que el primer componente explique la mayor proporción de la varianza, el segundo componente (ortogonal al primero) capture la siguiente mayor porción, y así sucesivamente. Desde un punto de vista técnico, el pca se basa en la descomposición de la matriz de covarianza (o correlación) de los datos, utilizando herramientas algebraicas como los vectores propios y valores propios, que determinan la dirección y magnitud de los componentes.




Fig.2. Proyección de una unidad de observación en la dirección definida por el vector unitario (Aluja et al. 2018)

Interpretación de salidas para PCA normalizado

De manera sucinta, la interpretación de las salidas de un PCA normalizado se concentran en la lectura de las varianzas o valores propios (*screeplots*) y de la lectura de mapas factoriales

(biplots).

- **Orden de los Componentes Principales:**


- El primer componente principal es la dirección en los datos que maximiza la varianza capturada.
- El segundo componente principal es ortogonal al primero y captura la mayor varianza restante, así sucesivamente.
- *Interpretación:* Cada componente principal subsiguiente explica menos varianza que el anterior. El orden refleja su importancia relativa.

- **Valores Propios:**

- Cada componente principal tiene un valor propio asociado, que cuantifica la varianza explicada por ese componente.
- *Interpretación:* Un valor propio alto indica que el componente asociado captura más varianza.
- *Interpretación:* Un valor propio cercano a cero sugiere que el componente es poco relevante.

- **Porcentaje de Varianza Explicada:**

- *Interpretación:* El *screeplot*, el cuales un gráfico de valores propios vs. componentes, ayuda a identificar cuántos componentes retener, identificando el punto de inflexión donde la curva se aplana.
- Si el primer componente principal explica el 70% de la varianza y el segundo el 20%, los dos primeros componentes resumen el 90% de la información original.






Fig.3. Screeplot para el caso de estudio de Chía.

- **Matriz de Cargas (Loadings):**

- Muestra la correlación entre cada variable original y los componentes.




Fig.4. Biplot para el caso de estudio de Chía.

Random Forest (RF)

Random Forest (RF) no es un método clásico de reducción de dimensionalidad como el PCA, pero puede utilizarse para este fin mediante la selección de variables (*feature selection*), identificando y eliminando características irrelevantes o redundantes.

⚠ Importante

- En el contexto de los Árboles de Decisión, tiene un significado particular, explicado a continuación.

- **Información:** En el contexto de los Árboles de Decisión, la información se utiliza para

guiar la división óptima de los datos en nodos homogéneos. Por ejemplo, la ganancia de información (basada en la reducción de entropía) o el índice de Gini miden cómo una variable divide los datos en grupos más “puros” respecto a la variable objetivo. Así, cada partición busca maximizar la información relevante, descartando ruido y construyendo un modelo predictivo eficiente.

- **Importancia por impureza:** también llamada *importancia Gini* o *importancia por reducción de varianza* es una métrica clave para medir cuánto contribuye cada variable a mejorar la calidad de las divisiones (*splits*) en los árboles de decisión. En cada nodo de un árbol de regresión se calcula una impureza para cada covariable de entrada:

$$\text{Gini} = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2$$

Estos valores son agregados de manera ponderada y normalizada para generar una sola métrica de importancia por covariable que sean comparables entre sí.

- *Valores altos:* La covariable aparece frecuentemente en nodos clave o cercanos a la raíz de los árboles.
- *Valores bajos:* La covariable no aporta en el modelado.

Caso de estudio

Selección de capas rásters para modelo *Deep Learning* de regresión del número de habitantes en Chía

Para efectos de reducir el almacenamiento y procesamiento de datos para un modelado de *Deep Learning*, se requiere seleccionar las capas de información del 2018 más relevantes para predecir el número de habitantes en unidades ráster para el municipio de Chia.

Consideraciones para el *notebook*

Un paso importante de la rutina del *notebook* utilizado para esta sesión, es la transformación de los rasters a un conjunto de datos utilizable por los métodos de la librería *scikit-learn*. En principio se usa una rotación y un apilado para convertir las unidades ráster en un conjunto de datos con observaciones ráster en las filas y capas de información como columnas de un

DataFrame.

```
tabla_datos = np.swapaxes(tabla_datos, 0, 2)
tabla_datos = pd.DataFrame(np.reshape(tabla_datos.shape[0]*tabla_datos.shape[1], tab
```

! Actividad

- **De acuerdo a los conceptos y formas de interpretación de salidas que fueron mencionadas en la sesión, deduzca las capas que usted considera relevantes para seleccionar, en orden de alimentar un modelo para la predicción de número de habitantes por unidades ráster en Chía.**

Conclusiones

💡 Nota

Como se mencionó, la reducción de dimensionalidad es un amplio campo de investigación dentro del conjunto de técnicas de *Machine Learning*. Se hace imprescindible familiarizarse con fundamento conceptual de estas para sacarles el mayor provecho, teniendo en cuenta que cada una de ellas tiene sus propias ventajas y desventajas, sabiendo además que bien dependerá del fenómeno que se esté abordando e incluso la estructura de los datos a investigar.

Documentación

1. [Documentación de la librería *pandas*](#)
2. [Documentación de la librería *matplotlib*](#)
3. [Documentación de la librería *scikit-learn*](#)

Referencias

- Awan, Abid Ali. 2025. "Understanding Dimensionality Reduction." DataCamp. DataCamp. <https://www.datacamp.com/tutorial/understanding-dimensionality-reduction>.

- Boigelot, Denis. 2011. "Several sets of (x, y) points, with the Pearson correlation coefficient of x and y for each set." https://en.wikipedia.org/wiki/Correlation#/media/File:Correlation_examples2.svg
- Aluja, T., Morineau, A., Sanchez, G. (2018) Principal Component Analysis for Data Science. <https://pca4ds.github.io>

[Guías de aprendizaje](#) © 2025 by [Aníbal Montero](#) is licensed under [CC BY-NC-ND 4.0](#) 

