

# Machine Learning No Supervisado

## Contents

- Análisis del Problema
- Caso de estudio
- Conclusiones
- Documentación
- Referencias

### ***Machine Learning no supervisado y aplicación de algoritmos***

Para el contenido de esta sesión, se exponen algunas de las técnicas utilizadas para la generación no supervisada de agrupamientos, junto con un ejercicio práctico basado en un *notebook* de Python para desplegar resultados con estas técnicas.

#### **Objetivos de la sesión**

- Introducir en el propósito y la necesidad de realizar agrupaciones de datos o *clusters*, revisando alternativas comunes para abordar el problema
- Entender el concepto que comprende la clasificación no supervisada para la reducción de dimensionalidad
- Entender los conceptos que comprenden algunas de las técnicas de *clustering*
- Entender el propósito de la validación de los agrupamientos realizados con alguna técnica de *clustering*
- Abordar un ejercicio práctico de *clustering* con diferentes técnicas no supervisadas de clasificación

#### **Recursos**

 [Recursos en línea de esta sesión](#)

## ! Actividad

- Dejar ejecutando el material de la sesión durante la clase, ya que puede tardar.

# Análisis del Problema

- **¿Qué significa clasificación no supervisada?** La clasificación no supervisada se refiere a un conjunto de algoritmos de *machine learning* que identifican patrones o grupos en datos sin usar etiquetas predefinidas (a diferencia de la clasificación supervisada). El objetivo es que los algoritmos descubran automáticamente estructuras latentes de agrupamiento en los datos basándose en similitudes o diferencias.

"Imagina que tienes un mapa de estrellas sin nombres. La clasificación no supervisada es como agruparlas por brillo, color y ubicación en el cielo, para construir nuevas y propias constelaciones."

- **¿Para qué se realiza clasificación no supervisada en una capa de información espacial?** En geoprocesamiento, se usa frecuentemente para:
  - *Segmentar imágenes satelitales*: por ejemplo, para diferenciar bosques, agua, zonas urbanas sin entrenar previamente un modelo de clasificación.
  - *Agrupar áreas con características similares*: por ejemplo, por densidad poblacional o por tipos de suelo.
  - *Representación de datos de forma comprimida*: por ejemplo, para simplificar bandas espectrales.

A continuación, se presentan algunas diferencias clave entre la clasificación supervisada y la no supervisada:

|                          | No supervisada                 | Supervisada                                   |
|--------------------------|--------------------------------|-----------------------------------------------|
| <b>Etiquetas</b>         | No se requieren                | Obligatorias (ej. polígonos de entrenamiento) |
| <b>Flexibilidad</b>      | Descubre patrones desconocidos | Limitado a clases predefinidas                |
| <b>Aplicación típica</b> | Exploración inicial de datos   | Modelos predictivos                           |

- **Tipos de algoritmos de aprendizaje no supervisado:** Las técnicas de clasificación no supervisada pueden clasificarse en los siguientes tipos y algunos nombres de los algoritmos comunmente más utilizados (Avi. 2025):
  - *Basado en centroides:* Agrupa los puntos de datos según su proximidad a los centroides.
    - K-means
    - K-means++
    - K-medoids++
  - *Basado en conectividad:* Agrupa los puntos según su proximidad entre clústeres.
    - Hierarchical Clustering
  - *Basado en densidad:* Agrupa los puntos según su densidad. Es más robusto para clústeres con densidades y formas variables que el clustering basado en centroides.
    - DBSCAN
    - OPTICS
    - HDBSCAN
    - DBSCAN++
  - *Basado en grafos:* Agrupa los puntos según la distancia entre grafos.
    - Affinity Propagation
    - Spectral Clustering
  - *Basado en distribución:* Agrupa los puntos según su probabilidad de pertenecer a la misma distribución.
    - Gaussian Mixture Models
  - *Basado en compresión:* Transforma los datos a un espacio de menor dimensión y luego realiza el clustering.
    - BIRCH

- PCA + K-means



#### Nota

Las opciones de algoritmos de aprendizaje no supervisado pueden variar de acuerdo al volumen de datos a analizar, a la estructura de datos y al fenómeno que se esté estudiando, por lo que las técnicas son numerosas.



#### Actividad

- **Realizar una charla con una IA de Procesamiento de Lenguaje Natural sobre más opciones de técnicas y aplicaciones de aprendizaje no supervisado, preguntando sobre dónde es más adecuada una u otra opción de técnica.**

## Caso de estudio

### Exploración de una imagen compuesta Sentinel en las bandas del espectro visible para Chía en 2018

Se requiere levantar una primera clasificación supervisada de coberturas de suelo en el municipio de Chía para 2018 y para facilitar el etiquetado de datos, se quieren explorar alternativas de etiquetas de clasificación no supervisada que permitan delimitar las coberturas de interés sin realizar una interpretación manual de toda la imagen.





Fig.1. Imagen de Chía para 2018 derivada de la composición de imágenes Sentinel. Elaboración propia.

A continuación se dará una breve explicación de los conceptos detrás de algunas de los algoritmos comunmente más utilizados.

## Consideraciones para el *notebook*

Un paso importante de la rutina del *notebook* utilizado para esta sesión, es la transformación de los rasters a un conjunto de datos utilizable por los métodos de la librería *scikit-learn*. En principio se usa una rotación y un apilado para convertir las unidades ráster en un conjunto de datos con observaciones ráster en las filas y capas de información cxomo columnas de un *DataFrame*.

```
tabla_datos = np.swapaxes(nrmlzd, axis1=0, axis2=2)
tabla_datos = pd.DataFrame( tabla_datos.reshape(num_col*num_fil,num_cap) )
tabla_datos = tabla_datos.rename(columns=dict( zip(range(3) , ['B4','B3','B2'] )))
```

## K-means

Su principal objetivo es organizar un conjunto de datos en K grupos o clusters, donde cada grupo se define por su centroide, es decir, el punto que representa el promedio de todas las observaciones asignadas a ese cluster.


- El siguiente paso a paso describe en rasgos generales el algoritmo:
  - *Paso 1, Inicialización:* Se elige el número de clusters K para determinar K centroides iniciales aleatorios (o con métodos más inteligentes como K-means++).
  - *Paso 2, Asignación:* Cada punto del conjunto de datos se asigna al cluster cuyo centroide esté más cercano (usando distancia euclidiana).
  - *Paso 3, Actualización:* Recalcula los centroides como el promedio de todos los puntos asignados a cada cluster.
  - *Paso 4, Convergencia:* Repite los pasos 2 y 3 hasta que los centroides ya no cambien significativamente o se alcance el número máximo de iteraciones.
- Ventajas:

- Escalable
- Limitaciones:
  - Sensibilidad a inicialización: Centroides aleatorios pueden dar resultados distintos.
  - Asume clusters esféricos: No funciona bien con formas irregulares.

## Sobre las salidas del *notebook*

Dentro del ejercicio práctico, se obtiene una representación tridimensional de la dispersión de los píxeles por sus valores de reflectancia y por los grupos generados en cada algoritmo utilizado, lo que permite entender el funcionamiento de cada uno de los algoritmos desde su comportamiento geométrico, tal y como se muestra a continuación para K-means:


Valores de píxeles y clusters por K-means. Sentinel Chía 2018



**Fig.2. Diagrama de dispersión para los valores de las bandas del espectro visible para los píxeles de la imagen de Chía en 2018.**


También se obtiene la distribución de los píxeles por los grupos generados en cada algoritmo utilizado, en donde se aprecia que algunos de los algoritmos tienen a discriminar objetos particulares o a generalizar su agrupamiento.





**Fig.3. distribución de los pixeles por los grupos generados por K-means.**

Finalmente, se obtiene la reconstrucción de la imagen generada desde los grupos que resultan de cada algoritmo utilizado, esto con el fin de permitir llevar los resultados a un software GIS para su análisis.






Fig.4. Agrupamiento por K-means resultado para la imagen compuesta Sentinel de Chía de 2018.

## Hierarchical clustering

Se distingue por su capacidad para organizar los datos en estructuras arbóreas llamadas dendrogramas, revelando relaciones jerárquicas entre los elementos. A diferencia de métodos como K-means que requieren especificar de antemano el número de clusters, el clustering jerárquico construye progresivamente una jerarquía de agrupamientos que permite explorar los datos a diferentes niveles de granularidad. Existen dos enfoques principales en el clustering jerárquico: el método aglomerativo, que comienza considerando cada punto como un cluster individual y va fusionando progresivamente los más similares, y el método divisivo, que parte de un único cluster que se va dividiendo recursivamente. En la práctica geoespacial, el enfoque aglomerativo es el más utilizado por su implementación más sencilla y resultados más interpretables.

- El siguiente paso a paso describe en rasgos generales el algoritmo:
  - *Paso 1, Inicialización:* Cada punto es un cluster individual.
  - *Paso 2, Cálculo de Matriz de Distancia:* Calcula la distancia entre todos los pares de clusters.
  - *Paso 3, Fusión Iterativa:* Une los dos clusters más cercanos en uno nuevo según un criterio de enlace.
  - *Paso 4, Repetición:* Repite los pasos 2 y 3 hasta que todos los puntos pertenezcan a un solo cluster.
- Ventajas:
  - No requiere especificar K inicial.
  - Visualización intuitiva con dendrogramas.
  - Útil para datos con estructuras jerárquicas naturales.
- Limitaciones:
  - Computacionalmente costoso para grandes datasets
  - Sensible a outliers y al criterio de enlace elegido.

## DBSCAN



Se fundamenta en la densidad de distribución de los puntos en el espacio. A diferencia de técnicas como K-means o clustering jerárquico, DBSCAN no asume formas específicas para los clusters ni requiere conocer de antemano el número de grupos, lo que lo hace particularmente valioso para el análisis de datos geoespaciales con patrones complejos. El funcionamiento de DBSCAN se basa en dos parámetros clave: el radio de búsqueda ( $\epsilon$ ) y el número mínimo de puntos (`min_samples`) necesarios para formar una región densa. El algoritmo clasifica los puntos en tres categorías fundamentales: puntos núcleo (core points) que tienen suficientes vecinos dentro del radio  $\epsilon$ , puntos frontera (border points) que están en los límites de los clusters, y puntos de ruido (noise points) que no pertenecen a ninguna agrupación densa. Esta distinción permite a DBSCAN identificar clusters de formas arbitrarias y, al mismo tiempo, detectar valores atípicos de manera efectiva.

- El siguiente paso a paso describe en rasgos generales el algoritmo:
  - *Paso 1, Selección inicial:* Elige un punto aleatorio no visitado.
  - *Paso 2, Búsqueda de vecinos:* Encuentra todos los puntos dentro del radio  $\epsilon$  (vecindario).
  - *Paso 3, Clasificación:* Si el vecindario tiene  $\geq \text{min\_samples}$ , forma un nuevo cluster. Si no, marca el punto como ruido (a menos que luego sea alcanzable desde otro cluster).
  - *Paso 4, Expansión del cluster:* Añade recursivamente todos los puntos alcanzables dentro de  $\epsilon$ .
  - *Paso 5, Repetición:* Repite hasta que todos los puntos estén visitados.
- Ventajas:
  - Descubre clusters de formas arbitrarias (no esféricas como en K-means).
  - Identifica y separa el ruido, es decir, es robusto a outliers.
  - No requiere conocer K a priori.
  - Funciona bien con datos espaciales (ej. coordenadas geográficas).
- Limitaciones:
  - Sensible a  $\epsilon$  y `min_samples`: Requiere ajuste cuidadoso.
  - Dificultad con clusters de densidad variable: Si los grupos tienen densidades muy distintas.
  - Desempeño en datos de alta dimensión afecta la métrica de distancia.

## Spectral Clustering

Se fundamenta en principios de teoría de grafos y álgebra lineal, destacando especialmente en escenarios donde los datos presentan estructuras complejas que los métodos tradicionales como K-means no pueden capturar adecuadamente. Este método transforma los datos originales en un espacio de características donde las relaciones no lineales se vuelven más evidentes y manejables, utilizando para ello el espectro (valores y vectores propios) de una matriz derivada de las similitudes entre los puntos de datos.

- El siguiente paso a paso describe en rasgos generales el algoritmo:
  - *Paso 1, Construir la Matriz de Similitud (W)*: Calcula las similitudes entre pares de puntos (ej. kernel Gaussiano:  $\exp(-\|x_i - x_j\|^2 / 2\sigma^2)$ ).
  - *Paso 2, Se calcula Matriz Laplaciana (L)*:  $L = D - W$ , donde D es la matriz diagonal de grados (suma de similitudes por fila). Opcional: Normalizar ( $L_{\text{norm}} = D^{-1/2} L D^{-1/2}$ ).
  - *Paso 3, Descomposición Espectral*: Calcula los  $k$  primeros vectores propios de L (asociados a los menores valores propios).
  - *Paso 4, Reducción y Clustering*: Crea una nueva matriz con los vectores propios como columnas y aplica K-means sobre las filas de esta matriz (datos transformados).
- Ventajas:
  - Captura relaciones no lineales en los datos (ej. círculos concéntricos).
  - Flexible a cualquier medida de similitud.
  - Efectivo en imágenes y redes complejas.
- Limitaciones:
  - Costoso computacionalmente:  $O(n^3)$  para matrices grandes (por la descomposición espectral).
  - Sensible a la elección de kernel y parámetros.
  - Requiere post-procesamiento (K-means en la representación espectral).

## BIRCH

Balanced Iterative Reducing and Clustering using Hierarchies) representa una solución innovadora para el análisis de agrupamiento en grandes volúmenes de información espacial, donde los métodos tradicionales resultan computacionalmente prohibitivos. Este enfoque, desarrollado específicamente para manejar conjuntos de datos masivos, se basa en una estructura de árbol altamente eficiente que resume las características clave de los grupos mediante una representación compacta llamada Clustering Feature (CF). En el corazón de

BIRCH se encuentra el CF-Tree, una estructura jerárquica que organiza los datos en subgrupos representados por vectores CF. Cada uno de estos vectores almacena tres elementos fundamentales: el número de puntos en el cluster (N), la suma lineal de sus valores (LS) y la suma de sus cuadrados (SS). Esta representación matemática permite calcular rápidamente medidas críticas como centroides, radios y distancias entre clusters sin necesidad de acceder a los datos originales, optimizando así el uso de memoria y tiempo de procesamiento.

- El siguiente paso a paso describe en rasgos generales el algoritmo:
  - *Paso 1, Construcción del CF-Tree*: Si un punto no cabe en ningún subcluster existente (según T), crea uno nuevo.
  - *Paso 2, Agrupamiento Global*: Aplica un algoritmo de clustering (ej. K-means) sobre los CFs de las hojas.
  - *Paso 3, Fase de Refinamiento (Opcional)*: Reasigna puntos a los clusters finales para mejorar precisión..
- Ventajas:
  - Complejidad lineal, ideal para big data.
  - Bajo uso de memoria POR Compresión de datos en CFs
  - Puede ser incremental, procesando nuevos datos sin reiniciarse.
  - Manejo de outliers: Puntos lejanos se almacenan en nodos especiales.
- Limitaciones:
  - Sensible a parámetros (B y T): Requieren ajuste cuidadoso.
  - Limitado a datos numéricos.
  - Menos preciso que métodos no incrementales (ej. DBSCAN) para formas complejas.

## Conclusiones

### Importante

- **El verdadero valor del clustering espacial emerge cuando estos patrones automáticamente detectados se confrontan con el conocimiento experto y se integran en flujos de trabajo más amplios. Esta transición de lo no supervisado a lo supervisado representa un ciclo virtuoso en el análisis geoespacial, donde la exploración inicial guiada por datos alimenta y valida procesos predictivos más estructurados. Como ilustración, podríamos considerar cómo los clusters derivados de imágenes multiespectrales mediante K-means pueden servir para estratificar el área de estudio y optimizar la recolección de muestras de campo, que a su vez entrenarán clasificadores más sofisticados.**

### Nota

Esta etapa de agrupamiento no supervisado adquiere especial relevancia cuando sirve como fase preliminar para procesos de clasificación supervisada. Los clusters generados pueden convertirse en valiosas fuentes para la creación de muestras de entrenamiento, reduciendo así el sesgo inherente a la selección manual de polígonos. Además, las características derivadas de estos agrupamientos - como distancias a centros de cluster o densidad local - enriquecen significativamente el espacio de características para los algoritmos supervisados posteriores. Sin embargo, es crucial reconocer que la calidad de los clusters espaciales no se mide únicamente mediante índices numéricos, sino que requiere una evaluación contextual que considere la coherencia geográfica, la escala de análisis y la aplicabilidad práctica para el problema concreto.

En última instancia, el clustering aplicado a datos espaciales no debe verse como un fin en sí mismo, sino como una poderosa herramienta de descubrimiento que, cuando se combina adecuadamente con métodos supervisados y validación experta, puede revelar patrones geográficos ocultos y generar insights accionables. La subjetividad inherente al proceso no es una limitación, sino una característica que refleja la complejidad misma de los fenómenos espaciales que estudiamos.

## Documentación

1. [Documentación de la librería \*numpy\*](#)
2. [Documentación de la librería \*pandas\*](#)

3. [Documentación de la librería \*rasterio\*](#)
4. [Documentación de la librería \*plotly\*](#)
5. [Documentación de la librería \*matplotlib\*](#)
6. [Documentación de la librería \*scikit-learn\*](#)

## Referencias

- Avi, C. (2025). Beyond KMeans: 6 Must-Know Types of Clustering Algorithms in Machine Learning. <https://blog.dailydoseofds.com/p/beyond-kmeans-6-must-know-types-of>

[Guías de aprendizaje](#) © 2025 by [Aníbal Montero](#) is licensed under [CC BY-NC-ND 4.0](#) 